

Aplicación de Reinforcement Learning en Drones para la Respuesta a Incendios.

Reporte Técnico Final.

Paola Rojas Domínguez

Abstract—Este reporte presenta el desarrollo inicial de una plataforma de simulación orientada al entrenamiento de drones mediante técnicas de aprendizaje por refuerzo para su aplicación en escenarios de respuesta a incendios. Durante una experiencia de vinculación en la empresa Skyspec, se construyó la infraestructura técnica y conceptual necesaria para habilitar, en fases posteriores, el entrenamiento de políticas de control autónomo. El proyecto integró tecnologías del ecosistema NVIDIA Omniverse, incluyendo Isaac Sim para simulación física avanzada e Isaac Lab para la definición de entornos de RL escalables, complementadas con herramientas de creación de activos 3D como Blender y motores interactivos como Unity. Se desarrolló un modelo tridimensional del dron, se implementaron sensores virtuales LiDAR e IMU conectados a ROS2, y se estableció un entorno modular capaz de definir observaciones, acciones y recompensas para experimentos futuros con algoritmos basados en PPO. Aunque el entrenamiento completo de políticas no forma parte del alcance de esta fase, el resultado constituye un avance para investigaciones futuras en navegación autónoma de drones en condiciones dinámicas y degradadas asociadas a incendios.

Index Terms—Omniverse, NVIDIA, Drones, Reinforcement Learning, Skyspec, Isaac Sim, Isaac Lab.

I. INTRODUCCIÓN

La Experiencia de Vinculación Internacional realizada en la empresa Skyspec constituyó una oportunidad para integrar conocimientos teóricos avanzados sobre simulación, robótica aérea, percepción computacional y aprendizaje por refuerzo con la fase inicial de un proyecto de investigación aplicado a la navegación autónoma de drones en escenarios de incendio. Skyspec es una compañía especializada en el análisis de datos de observación de la Tierra y en el desarrollo de tecnologías para la detección y monitoreo de sustancias químicas peligrosas en el medio ambiente. En este contexto, la empresa ha comenzado a explorar el potencial de los vehículos aéreos no tripulados como plataformas capaces de operar en entornos afectados por fuego, humo y daño estructural, donde los instrumentos convencionales pueden fallar o volverse inaccesibles. Esta iniciativa busca, a largo plazo, entrenar drones mediante técnicas de Reinforcement Learning para identificar fuentes de incendio, navegar con seguridad en condiciones dinámicas y eventualmente colaborar de forma coordinada.

Durante la estancia, el alcance real del proyecto se basó en sentar las bases conceptuales, técnicas y experimentales necesarias para desarrollar dicha plataforma. Esto implicó un estudio profundo de NVIDIA Omniverse, Isaac Sim e Isaac Lab —las tres herramientas fundamentales para construir entornos simulados físicamente coherentes y controlados— así

como un análisis riguroso del aprendizaje por refuerzo, sus limitaciones y sus posibles aplicaciones en sistemas aéreos. Dado que el proyecto original estaba planeado para un equipo de cinco integrantes y finalmente fue ejecutado por una sola persona, las actividades se centraron en construir una base sólida de comprensión, experimentación y diseño, más que en obtener resultados finales de navegación autónoma avanzada. Aun así, los avances teóricos y técnicos constituyen un aporte significativo para el desarrollo futuro del proyecto y para la integración de metodologías de RL en sistemas de respuesta a incendios.

II. DESARROLLO

La presente sección describe, de manera estructurada y cronológica, el proceso de construcción técnica llevado a cabo durante la experiencia de vinculación en Skyspec. Se detallan los fundamentos teóricos que guiaron las decisiones de diseño, las herramientas empleadas en cada etapa y la evolución progresiva del sistema desde modelos visuales iniciales hasta la creación de un entorno especializado para aprendizaje por refuerzo en drones. Asimismo, se documentan las iteraciones técnicas, los desafíos de compatibilidad y las estrategias de integración que permitieron consolidar un pipeline funcional basado en NVIDIA Omniverse, Isaac Sim e Isaac Lab. Este apartado expone, por tanto, no solo los resultados alcanzados, sino también el razonamiento técnico y metodológico que fundamenta la arquitectura final del proyecto.

A. Fundamentos teóricos

1. NVIDIA Omniverse y OpenUSD

NVIDIA Omniverse se concibe como una plataforma de interoperabilidad y simulación orientada a entornos 3D de alta fidelidad, diseñada para conectar herramientas, datos y procesos en un flujo de trabajo colaborativo sobre el estándar Universal Scene Description (USD). La arquitectura de Omniverse apalanza USD como formato de composición no destructiva que mantiene jerarquías, transformaciones y metadatos de escena, permitiendo que distintas aplicaciones (modeladores, motores de física, renderizadores) compartan una misma representación del mundo virtual. Esta aproximación facilita la construcción de “digital twins” y entornos físicamente coherentes donde la edición, la simulación y el renderizado pueden coexistir y sincronizarse en tiempo real. Desde la perspectiva de la investigación aplicada a robótica,

la importancia clave de Omniverse reside en su capacidad para reunir geometría, materiales (MDL/OmniPBR), físicas avanzadas (PhysX), y plugins o “connectors” que exportan e importan escenas desde herramientas como Blender, Unity o sistemas CAD, de modo que los modelos diseñados en distintos entornos puedan reutilizarse sin pérdidas de integridad semántica ni visual. La combinación de OpenUSD y conectores forma la columna vertebral técnica que convierte a Omniverse en un hub para la creación de datasets sintéticos, ensayos de control y validaciones visuales a escala industrial (NVIDIA Omniverse; Connect SDK; Create MDL material). [1]

2. Isaac Sim e Isaac Lab: simulación robótica sobre Omniverse

Isaac Sim se presenta como el componente especializado dentro del ecosistema Omniverse destinado a la simulación robótica con física realista y soporte para sensores virtuales. Construido sobre la infraestructura de Omniverse, Isaac Sim integra un motor físico capaz de modelar articulaciones, dinámica de cuerpos rígidos, fricción y contactos, así como sensores tradicionales en robótica (cámaras RGB-D, LiDAR, IMU). Su diseño facilita la importación de articulaciones y URDF/URDF-like descriptions, la instrumentación de escenas con observaciones y la integración con middleware robótico como ROS2 para cerrar el bucle entre simulación y software de control real. [4]

Isaac Lab, por su parte, se concibe como una capa orientada a la creación de entornos de aprendizaje por refuerzo y al entrenamiento a gran escala: abstrae la construcción de episodios, el muestreo de observaciones, las políticas y recompensas, y ofrece plantillas para acelerar experimentos con agentes, incluidas técnicas para paralelización y recolección masiva de experiencias en GPU. Para proyectos de drones, la combinación Isaac Sim + Isaac Lab posibilita definir agentes que actúan en espacios continuos, incorporar ruido sensor-actuador, y ejecutar ciclos de entrenamiento con un balance entre fidelidad física y throughput computacional que resulta crítico para la viabilidad del aprendizaje. La interoperabilidad con USD y Omniverse permite además generar escenarios variados y sincronizar visualización y datos de telemetría para análisis post-hoc. [5]

3. Simuladores especializados para drones y OmniDrones

El entrenamiento de controladores de aeronaves multirrotor en simulación requiere herramientas que representen con suficiente detalle la dinámica propulsiva, el acoplamiento entre actuadores y el cuerpo rígido, y la interacción con perturbaciones ambientales (viento, turbulencia, colisiones). Plataformas específicas para investigación en drones, como OmniDrones, combinan modelos de dinámica multi-rotor (implementados sobre Isaac Sim) con una API orientada a benchmarks de RL: tareas de hover, seguimiento de trayectorias, recuperación ante perturbaciones, transporte cooperativo y configuraciones sobreadaptadas. Estas plataformas incluyen múltiples modalidades sensoriales (IMU, cámaras, segmentación), varios modos de control (por rotores, por velocidad, por tasas), y suites de rutina para benchmarking con algoritmos clásicos de RL

(PPO, SAC, TD3) y variantes multiagente. La disponibilidad de modelos prediseñados reduce la barrera de entrada a experimentos reusables y comparables, y la alta eficiencia en recolección de datos (pasos por segundo) es determinante para el entrenamiento con métodos basados en exploración. [6]

4. Interoperabilidad en la cadena de creación: Blender, Unity y repositorios 3D

La cadena de creación de activos visuales y físicos para simulación incluye habitualmente etapas de modelado (Blender, Maya), empaquetado (FBX, OBJ, USD) y sincronización con el simulador. Blender aporta herramientas avanzadas de modelado, mapeo UV, definición de materiales y rigging; Unity y otros motores proveen pipelines de ejecución en tiempo real. El uso de USD y conectores Omniverse facilita la preservación de materiales (OmniPBR/MDL) y transformaciones entre aplicaciones, minimizando pérdidas de semántica. Por otro lado, los repositorios de modelos 3D (Sketchfab, GrabCAD, CG-Trader, Thingiverse) son fuentes valiosas de geometría que, con la conversión y limpieza adecuada, pueden alimentar entornos de simulación y generación de datos sintéticos. Un aspecto crítico en el proceso de integración es la validación de pivotes, centrado de masas, jerarquía de articulaciones y mapeo correcto de materiales, elementos que condicionan tanto la apariencia como la física simulada. [10]

5. Fundamentos de Reinforcement Learning aplicados a robótica aérea

El Reinforcement Learning formaliza el problema del control óptimo como un proceso de decisión de Markov (MDP), donde un agente percibe un estado, ejecuta una acción y recibe una recompensa, con el objetivo de maximizar la suma de recompensas acumuladas. En robótica aérea, el espacio de estados incluye posiciones, velocidades, tasas angulares y lecturas sensoriales; el espacio de acciones puede ser continuo (escala de impulsos, torque o consigna de velocidades) y la función de recompensa debe articular objetivos múltiples (estabilidad, seguridad, eficiencia energética, evitación de obstáculos). Algoritmos modernos como Proximal Policy Optimization (PPO) y Soft Actor-Critic (SAC) han demostrado robustez en entornos continuos y ruidosos; no obstante, su convergencia depende de la calidad de la simulación, del diseño de la recompensa y de la exploración. El aprendizaje jerárquico (HRL) aporta una estrategia para descomponer tareas complejas en subobjetivos manejables: un nivel alto define metas intermedias en un espacio reducido, mientras que un nivel bajo ejecuta acciones continuas para alcanzarlas. Este esquema es particularmente relevante para maniobras compuestas y para acelerar la exploración en tareas de larga-horizonte, como el despegue, la navegación en pasillos o la recuperación tras perturbaciones. [6]

6. Inspiraciones neurobiológicas y diseño de recompensas

Las teorías de neuromodulación, como las propuestas por Kenji Doya, ofrecen metáforas útiles para el diseño de sistemas de control y recompensa: distintos moduladores biológicos pueden interpretarse como señales de ajuste de parámetros (exploración/explotación, sensibilidad al riesgo, tolerancia al castigo) que en RL se traducen en escalamiento de recompensas.

sas, regularización de políticas o ajuste de tasas de aprendizaje. La inclusión de recompensas parciales (shaping) es una técnica práctica para guiar el aprendizaje en escenarios donde el éxito final es infrecuente. No obstante, el shaping mal diseñado puede inducir políticas indeseables (satisficing local), por lo que su empleo exige experimentación y validación cuidadosa. [11]

7. Síntesis: integración teórica para el proyecto

La suma de estos fundamentos establece el panorama teórico sobre el cual se fundamenta el proyecto de RL en drones para incendios. Omniverse aporta interoperabilidad y renderizado; Isaac Sim provee la física y los sensores virtuales necesarios para validar comportamientos; Isaac Lab posibilita la encapsulación de agentes y experimentos de RL a escala; mientras que las técnicas modernas de RL, HRL y estrategias de transferencia constituyen el corpus técnico que guiará el diseño de políticas y la definición de recompensas. La articulación coherente de estas piezas —acompañada de prácticas formales de validación y mitigación del gap sim-to-real— es condición necesaria para que las políticas entrenadas en simulación resulten útiles para misiones reales en entornos afectados por incendios.

B. Desarrollo del proyecto en Skyspec

1. Primeros experimentos visuales: animación del dron en Blender

El desarrollo del proyecto comenzó con la exploración de herramientas de modelado y animación tridimensional, un paso esencial para comprender la estructura visual y geométrica del dron que posteriormente sería empleado en motores de simulación física. Blender se seleccionó como punto de partida debido a su capacidad para manipular jerarquías de objetos, ajustar pivotes, modelar elementos estructurales y realizar animaciones precisas sin depender aún de un motor físico complejo. El objetivo inicial no era recrear dinámicas de vuelo, sino establecer una comprensión detallada de la composición del dron, de la relación entre sus hélices y el cuerpo principal y del modo en que podía representarse su movimiento mediante rotaciones, transformaciones y trayectorias programadas. Durante esta etapa se generó una animación completa en la cual el dron realizaba un despegue controlado y describía un pequeño recorrido en el aire siguiendo instrucciones definidas mediante Python.

Este primer acercamiento fue más relevante de lo que podría parecer a simple vista. Por un lado, permitió identificar la importancia de la correcta ubicación de los pivotes de las hélices, ya que un error en la orientación o en la posición del origen podía afectar todo el pipeline de simulación posterior. Por otro lado, facilitó la exportación de activos 3D en formato USD, un paso crítico en la filosofía de trabajo de NVIDIA Omniverse, donde los modelos adquieren un rol modular y editable que puede reutilizarse en múltiples entornos. La experiencia con Blender también permitió distinguir entre animación keyframeada y simulación física, lo cual resultó importante para comprender las limitaciones y posibilidades

de cada etapa del proyecto, fortaleciendo las bases para las siguientes fases del desarrollo.

2. Exploración interactiva en motores de simulación: movimiento WASD y modelado sensorial en Unity

Una vez consolidado el modelo del dron en Blender, el proyecto avanzó hacia Unity con el propósito de introducir interactividad mediante un controlador en tiempo real. El motor de Unity ofreció un entorno accesible para evaluar el comportamiento del dron bajo entradas del usuario y experimentar con físicas simplificadas. Se implementó un sistema de control basado en las teclas estándar WASD y la barra espaciadora, lo cual permitió desplazar el dron y simular movimientos básicos de vuelo, como ascenso leve, desplazamientos laterales y avances o retrocesos controlados. Al manipular el dron mediante un script en C#, fue posible observar la respuesta del modelo ante fuerzas aplicadas directamente sobre su rigidbody y evaluar la estabilidad general del sistema dentro de un entorno no especializado en simulación aérea.

La fase desarrollada en Unity incluyó también la simulación de un sensor LiDAR básico. Este componente permitió generar datos tridimensionales que representaban distancias a obstáculos en el entorno, un primer acercamiento a los aspectos sensoriales que posteriormente serían esenciales para la navegación autónoma. Aunque el LiDAR de Unity no presenta la fidelidad ni el realismo físico de los sensores integrados en Isaac Sim, brindó la oportunidad de comprender la estructura de una nube de puntos, la frecuencia de adquisición y la relación entre la orientación del dron y la lectura espacial. Estos experimentos demostraron la importancia de los sensores exteroceptivos en misiones donde la visibilidad puede verse afectada por humo o condiciones ambientales adversas, como sucede en escenarios reales de incendios.

Unity permitió así desarrollar una comprensión intuitiva sobre el comportamiento del dron en un ambiente tridimensional interactivo, pero también reveló sus limitaciones, especialmente en lo relativo a la precisión física y a la integración directa con sistemas de comunicación robótica como ROS2. Estas limitaciones hicieron necesaria la transición hacia motores más avanzados, donde el enfoque no fuera únicamente la animación o el control en tiempo real, sino la simulación física rigurosa y la integración con algoritmos de aprendizaje automático.

3. Integración de sensores y simulación física avanzada: LiDAR e IMU en Isaac Sim conectados con ROS2

La siguiente etapa consistió en trasladar los experimentos previos a un entorno capaz de reproducir con mayor fidelidad las dinámicas y condiciones físicas de un dron real. NVIDIA Isaac Sim se convirtió en la herramienta principal para este objetivo, debido a su estrecha relación con el ecosistema Omniverse y su capacidad para simular sensores complejos. En este entorno se integró por primera vez un sensor LiDAR simulado con características más cercanas a un dispositivo físico real, extendiendo así los resultados obtenidos en Unity. El LiDAR en Isaac Sim generó nubes de puntos más detalladas y permitió probar configuraciones de intensidad, ruido, tasa de muestreo y campo de visión, aspectos fundamentales

para comprender el comportamiento del sensor en entornos degradados.

Un elemento clave de esta etapa fue la conexión entre Isaac Sim y ROS2. A través de puentes de comunicación, los datos generados por el LiDAR fueron publicados en tópicos ROS, permitiendo que nodos externos procesaran la información como si proviniera de un sensor físico. Esta conexión representó el primer paso hacia un pipeline de simulación-hardware que permitirá, en fases futuras, realizar pruebas híbridas donde parte del procesamiento ocurre en simulación y parte en sistemas reales.

Además del LiDAR, se integró un sensor IMU, otro componente indispensable para el control del dron. La IMU simulada generó información sobre aceleraciones lineales, velocidades angulares y orientación, lo cual permitió reproducir de manera consistente la percepción que un dron tendría de sus movimientos en un entorno físico. Este doble sistema sensorial —LiDAR exteroceptivo y IMU proprioceptiva— proporcionó por primera vez un marco completo de observación que más adelante podrá alimentar las políticas del agente de aprendizaje por refuerzo. La experiencia en Isaac Sim consolidó así la base para pasar del control manual y la experimentación visual, hacia la construcción de entornos avanzados que permitan integrar dinámica precisa, sensores realistas y comunicación robótica.

4. Construcción de la infraestructura de aprendizaje por refuerzo en Isaac Lab

La parte más compleja y demandante del proyecto comenzó con la creación de un entorno propio de aprendizaje por refuerzo dentro de Isaac Lab. Este simulador —derivado directamente de Isaac Sim— proporciona herramientas optimizadas para entrenamiento paralelo, interacción directa con GPUs y diseño modular de tareas robóticas. El objetivo era establecer un entorno capaz de entrenar, en un futuro, un dron autónomo que pudiera estabilizarse, desplazarse y reaccionar ante perturbaciones en escenarios inspirados en incendios.

La estructura del proyecto se organizó siguiendo las recomendaciones de la documentación oficial de Isaac Lab. Dentro de un paquete dedicado, se incluyeron un archivo USD del dron, módulos de configuración del entorno, definiciones del espacio de observación, diseño de acciones, funciones de recompensa y scripts para ejecutar algoritmos basados en SKRL, incluyendo PPO como punto de partida. El árbol del proyecto refleja esta arquitectura modular e incluye directorios específicos para tareas, agentes, configuración YAML, funciones de recompensa y scripts de prueba como random_agent.py.

El trabajo en esta etapa requirió comprender la transición conceptual entre Isaac Sim e Isaac Lab. Mientras Isaac Sim se enfoca en la simulación física, Isaac Lab organiza esa simulación dentro de un marco de aprendizaje por refuerzo, donde cada episodio, estado, acción y recompensa debe ser definido explícitamente. Esto implicó aprender la estructura del MDP, generar abstracciones del comportamiento del dron, definir qué sensores constituirían el estado observado por el agente, calibrar los parámetros de simulación y resolver múltiples problemas de compatibilidad entre versiones del

simulador y del motor de física.

5. Obstáculos técnicos, compatibilidad, iteraciones y reformulación de la arquitectura

A lo largo del desarrollo del entorno de RL, surgieron numerosos problemas técnicos que demandaron reestructuraciones profundas. La migración entre versiones de Isaac Sim y su instalación mediante el paquete pip ocasionó inconsistencias respecto a la documentación oficial, lo cual llevó a múltiples intentos fallidos en los que módulos enteros habían sido modificados o deprecated. En varios puntos del proyecto fue necesario redefinir archivos de configuración, ajustar rutas, corregir imports obsoletos y reescribir secciones enteras del código para alinearlos con la versión disponible del simulador.

Estas dificultades no retrasaron el avance de manera improductiva; al contrario, permitieron comprender la arquitectura interna de Isaac Lab y el modo en que interactúan sus componentes fundamentales. Los intentos previos —designados como Intento 1 e Intento 2— constituyen un registro metodológico del proceso de depuración, revelando la evolución en la definición de acciones, la integración del dron con el motor físico y la adaptación del entorno a los parámetros del agente de RL. Además, estos obstáculos permitieron consolidar habilidades críticas en diagnóstico de errores, rastreo de dependencias y comprensión de estructuras modulares complejas dentro de entornos de simulación robótica avanzados.

6. Estado actual del sistema y bases consolidadas para entrenamiento futuro

En su estado actual, el proyecto presenta una estructura funcional que integra la geometría del dron en USD, sensores simulados en Isaac Sim, comunicación mediante ROS2 e infraestructura inicial para entrenamiento con Isaac Lab. Aunque la política del agente aún no ha sido entrenada, todos los componentes fundamentales han sido establecidos: el entorno existe, la arquitectura está definida, el simulador puede ejecutarse, el LiDAR y la IMU transmiten datos y los archivos de configuración del agente se encuentran preparados para etapas posteriores de capacitación.

El proyecto continúa siendo una fase temprana de un objetivo mayor, y es importante recordar que originalmente estaba destinado a un equipo de cinco integrantes. No obstante, los avances logrados han consolidado un pipeline robusto que servirá como base para entrenamientos futuros más complejos, como hover estable, navegación guiada, recuperación ante perturbaciones y, eventualmente, toma de decisiones autónomas en escenarios afectados por humo, calor y geometría cambiante. La infraestructura creada durante esta experiencia constituye, en sí misma, un logro técnico significativo y un punto de partida estratégico para el objetivo final de Skyspec: desarrollar un sistema de drones inteligentes capaces de operar con seguridad y eficacia en entornos comprometidos por incendios.

III. CUMPLIMIENTO DE OBJETIVOS

El objetivo general del proyecto consistía en iniciar el desarrollo de modelos de aprendizaje por refuerzo (Reinforcement Learning, RL) orientados al entrenamiento de drones capaces

de navegar en entornos dinámicos relacionados con incendios. Considerando que este trabajo correspondía a la primera etapa de un proyecto originalmente planeado para un equipo de cinco integrantes, se adoptó un enfoque realista centrado en construir los cimientos técnicos, teóricos y metodológicos que permitirán desarrollar los sistemas autónomos en fases posteriores. Desde esta perspectiva, el cumplimiento de los objetivos debe entenderse no en términos de productos finales completamente operativos, sino como la consolidación de una infraestructura sólida sobre la cual podrá construirse la parte más avanzada del proyecto.

En esta etapa se alcanzaron plenamente los objetivos relacionados con la comprensión conceptual del aprendizaje por refuerzo, sus componentes fundamentales, y su aplicación a sistemas robóticos. Asimismo, se cumplieron los objetivos vinculados con el estudio, evaluación y uso práctico de tecnologías clave como Omniverse, Isaac Sim e Isaac Lab, que constituyen la base del ecosistema de simulación avanzado empleado en este proyecto. La familiarización con el diseño de entornos de simulación, el análisis de modelos de drones, el procesamiento de sensores como LiDAR e IMU y la integración con ROS2 representaron logros significativos que contribuyeron a establecer la arquitectura que posteriormente permitirá entrenar políticas avanzadas.

Si bien algunos objetivos específicos asociados con el entrenamiento completo de políticas óptimas, la colaboración multi-agente, la transferencia de políticas entre drones heterogéneos o el análisis comparativo cuantitativo no pudieron desarrollarse aún debido a la etapa incipiente del proyecto, se construyeron los elementos estructurales necesarios para que dichas actividades puedan llevarse a cabo en un futuro cercano. Esto incluye la creación de un entorno personalizado en Isaac Lab, la configuración de agentes con algoritmos PPO mediante SKRL, la generación del modelo tridimensional del dron y la integración sensorial con simulación física avanzada.

En síntesis, el proyecto cumplió sus objetivos dentro de los alcances realistas establecidos para esta fase. Los avances obtenidos proporcionan una base metodológica sólida y un entendimiento técnico profundo que facilitarán tanto la continuación del proyecto como la incorporación de futuros integrantes. La claridad conceptual y la infraestructura creada aseguran que las etapas subsiguientes puedan avanzar con mayor rapidez y coherencia técnica.

A. Evaluación del cumplimiento de los objetivos específicos

A continuación se presenta la evaluación detallada de cada uno de los objetivos específicos planteados originalmente en el anteproyecto, manteniendo su estructura en viñetas para preservar la trazabilidad entre la planificación y su ejecución.

1) *Estudio de Reinforcement Learning (RL) aplicado a robots en general:* Este objetivo fue cumplido de manera completa. Se desarrolló un estudio sistemático del RL, abarcando tanto la teoría fundamental como su relación con sistemas robóticos autónomos.

- Analizar en detalle los componentes principales del RL. Se cumplió ampliamente. Se estudiaron la función de recompensa, la política, los valores (value functions), la

exploración-explotación, la estructura de episodios y la definición formal de un entorno MDP. Este análisis fue esencial para construir más adelante el entorno en Isaac Lab.

- Mapear los componentes del RL hacia subsistemas específicos del dron. Cumplido parcialmente pero con profundidad conceptual. Se establecieron correspondencias entre observaciones (sensores), acciones (motores), recompensas (estabilidad, altura, actitud) y estados del dron. Aunque todavía no se entrenó una política final, el mapeo conceptual quedó completamente elaborado.
- Entrenar y evaluar la estabilidad de vuelo, precisión y robustez mediante RL. Este punto no pudo concretarse totalmente debido a que el entorno aún no ha pasado a la fase de entrenamiento masivo. Sin embargo, se construyó la infraestructura necesaria para que este entrenamiento se realice en la siguiente etapa, incluyendo la configuración de PPO y SKRL, la definición del entorno en Isaac Lab y los sensores simulados.

2) *Implementar RL para que los drones aprendan rutas óptimas y seguras:* Este objetivo no se logró en su totalidad, ya que corresponde a una etapa posterior que requiere contar primero con un entorno estable y un modelo de dron completamente articulado. No obstante, se sentaron las bases fundamentales para lograr esto, incluyendo la simulación sensorial y la integración con ROS2.

3) *Utilizar simulaciones 3D en NVIDIA Isaac Sim para entrenar modelos de navegación basados en RL:* Este objetivo fue cumplido parcialmente. Isaac Sim se utilizó intensivamente para generar entornos de prueba, simular sensores LiDAR e IMU, evaluar modelos 3D del dron y preparar el escenario donde se ejecutará el entrenamiento. Aún no se logró completar el proceso de entrenamiento final, pero se alcanzaron los pasos preparatorios indispensables.

4) *Entrenar modelos 3D de drones en entornos virtuales realistas dentro de Isaac Sim empleando estrategias de IA:* Este objetivo no está completamente realizado, pero quedó habilitado técnicamente. Se integró el modelo USD del dron, se configuraron sensores, se analizaron dinámicas y se preparó el entorno Isaac Lab que permitirá realizar el entrenamiento.

5) *Ejecutar simulaciones, analizar desempeño y retroalimentar el ciclo entrenamiento-ejecución:* Este objetivo se encuentra en progreso. Se realizaron simulaciones manuales y pruebas del entorno, pero el ciclo completo de entrenamiento-evaluación-ajuste aún no se implementa debido a la etapa prematura del proyecto. Sin embargo, la plataforma está lista para ejecutarlo.

6) *Repetir experimentos con múltiples configuraciones de drones:* Este objetivo no pudo desarrollarse todavía, dado que apenas se consolidó el primer modelo funcional. No obstante, se estudiaron modelos alternativos y se construyó la base conceptual para gestionar configuraciones variables.

7) *Establecer comparaciones cuantitativas de eficiencia, estabilidad y velocidad de aprendizaje:* Este objetivo depende del entrenamiento final de las políticas, por lo que aún no es alcanzable. Los mecanismos para registrar métricas ya están previstos mediante SKRL y los logs de Isaac Lab.

8) Transferir políticas entrenadas entre diferentes drones:

Este objetivo avanzó únicamente a nivel conceptual. Se analizaron los requisitos para la transferencia (similitudes dinámicas, normalización de observaciones, compatibilidad en espacios de acción), pero no se implementó aún debido a la falta de políticas entrenadas.

9) Entrenar entre 2 y 5 drones para generar un modelo colaborativo multi-agente: Este objetivo pertenece a una etapa avanzada del proyecto. No se desarrolló, pero se estudió la literatura necesaria y los requisitos para RL multi-agente en Isaac Lab.

10) Entrenar y evaluar modelos colaborativos con diferentes combinaciones de drones: Al igual que el objetivo anterior, este punto corresponde a una fase madura del proyecto y no pudo ser alcanzado en esta etapa.

IV. FUNCIONES DESEMPEÑADAS

Las funciones desempeñadas durante la estancia abarcaron un conjunto amplio de actividades técnicas, analíticas y de investigación, todas orientadas a establecer las bases conceptuales y operativas del proyecto de aprendizaje por refuerzo aplicado a drones para escenarios de incendio. Una parte sustantiva del trabajo consistió en el estudio riguroso del ecosistema tecnológico de NVIDIA Omniverse, con particular énfasis en su estructura basada en USD, la lógica de composición de escenas y la integración con motores de simulación física. Este proceso incluyó el análisis de la documentación técnica, la revisión de arquitecturas existentes y la experimentación directa con herramientas destinadas al modelado tridimensional, la representación jerárquica de robots y la interoperabilidad entre plataformas de simulación.

Asimismo, se desempeñaron funciones relacionadas con la implementación práctica dentro de Isaac Sim. Estas actividades incluyeron la configuración de escenas de prueba, la manipulación de modelos 3D del dron, la importación y evaluación de recursos digitales, la simulación de sensores LiDAR e IMU y la validación inicial del comportamiento físico del modelo bajo diferentes condiciones de vuelo. Fue necesario trabajar con el motor de física, ajustar parámetros de colisión, materiales, articulaciones y sensores, y verificar la compatibilidad de las estructuras del dron con los módulos de simulación. Estas funciones permitieron adquirir una comprensión precisa de las capacidades y limitaciones de la plataforma y constituyeron un paso esencial para migrar el proyecto hacia Isaac Lab.

En cuanto al aprendizaje por refuerzo, se realizaron funciones de análisis conceptual, diseño preliminar y configuración inicial dentro de Isaac Lab. Esto incluyó la revisión detallada del modelo de entorno basado en MDP, el estudio de la arquitectura de agentes compatible con SKRL y la construcción parcial de un entorno personalizado para un dron, integrando observaciones sensoriales, espacios de acción y la estructura básica de recompensas. Estas funciones permitieron establecer la arquitectura técnica que sostendrá las futuras etapas de entrenamiento, aunque todavía no se ha alcanzado la fase final de ejecución debido a la complejidad del sistema y a la etapa inicial del proyecto.

Paralelamente, se realizaron funciones de documentación, sistematización de conocimientos y análisis crítico. Se elaboraron reportes teóricos que abarcaron desde los fundamentos del aprendizaje por refuerzo hasta los principios de simulación robótica, control de sistemas, cinemática, integración sensorial, navegación autónoma y diseño de trayectorias. Estas tareas permitieron consolidar un marco teórico robusto que servirá de referencia para las etapas futuras del proyecto y facilitarán la incorporación eventual de nuevos integrantes.

Finalmente, se desempeñaron funciones complementarias relacionadas con el estudio preliminar de metodologías de visión por computadora, dado que estas serán indispensables para la detección de puntos calientes, humo o anomalías térmicas en entornos de incendio. Se exploraron modelos de percepción visual, técnicas de segmentación y estrategias de integración sensorial con drones autónomos, con el fin de proyectar las capacidades futuras del sistema.

En su conjunto, las funciones desempeñadas permitieron integrar teoría, implementación técnica, simulación física, análisis crítico y documentación académica, sentando una base interdisciplinaria sólida para la continuación del proyecto y fortaleciendo la comprensión integral de los procesos necesarios para desarrollar drones autónomos entrenados mediante aprendizaje por refuerzo en entornos complejos.

V. ACTIVIDADES MÁS IMPORTANTES REALIZADAS Y SU CONTRASTE CON LAS PLANTEADAS INICIALMENTE

Las actividades desarrolladas durante la estancia se concentraron en establecer los fundamentos técnicos, conceptuales y metodológicos necesarios para un proyecto cuyo alcance original había sido diseñado para un equipo de cinco estudiantes y cuya complejidad implica múltiples fases de experimentación, validación y ajuste. En el anteproyecto se planteaba el desarrollo progresivo de un sistema completo de aprendizaje por refuerzo para drones en entornos relacionados con incendios, abarcando desde la construcción de modelos 3D y el dominio de las herramientas de simulación, hasta la implementación de agentes autónomos, la transferencia de políticas entre plataformas aéreas y la colaboración multi-agente. Dado que el proyecto se encontraba en una etapa inicial y el desarrollo debía ser realizado por una sola persona, las actividades se orientaron a crear la infraestructura teórica y técnica que hará posible la continuidad en fases futuras.

Un primer conjunto de actividades se centró en la exploración y comprensión profunda del ecosistema de NVIDIA Omniverse, particularmente de su arquitectura orientada a USD, sus herramientas de diseño y su enfoque de simulación distribuida. Esta etapa implicó no únicamente la lectura sistemática de documentación técnica, sino también la experimentación directa con la manipulación de modelos 3D, la ejecución de simulaciones básicas, la evaluación de materiales, colisiones y articulaciones, y el análisis del flujo de trabajo recomendado para la creación de robots personalizados. Estas actividades permitieron entender los principios de interoperabilidad entre Omniverse, Blender, Unity, ROS e Isaac Sim, identificando ventajas, limitaciones y oportunidades de integración. Dentro de este proceso se desarrollaron animaciones

preliminares del dron en Blender y se realizaron pruebas de control manual y simulación WASD en Unity, lo que permitió familiarizarse con la representación dinámica del dron y con el comportamiento esperado de sus ejes y motores en un entorno virtual.

En una segunda fase, se ejecutaron actividades específicas en Isaac Sim, herramienta central para el proyecto. Se implementaron simulaciones de sensores LiDAR e IMU, integrando gradualmente estas salidas con ROS para comprender la estructura de publicación, sus frecuencias, las transformaciones de marcos de referencia y los formatos de mensajes empleados para percepción tridimensional. Estas actividades fueron de gran importancia porque permitieron validar que el modelo del dron y sus sensores podían conectarse correctamente a pipelines de robótica ya establecidos, y además ofrecieron una primera aproximación a la percepción autónoma necesaria para la navegación en entornos complejos como los asociados a incendios.

Posteriormente, una parte considerable del trabajo se orientó a la creación del proyecto en Isaac Lab, atendiendo a la arquitectura definida en el anteproyecto. Esta etapa consistió en desarrollar la estructura base del entorno de entrenamiento mediante RL, integrando carpetas de tareas, agentes, configuraciones en YAML, scripts para ejecutar entrenamiento con SKRL, archivos de entorno, módulos de MDP, recompensas preliminares y extensiones asociadas. La actividad incluyó iteraciones continuas de revisión, depuración y adaptación debido a incompatibilidades entre versiones de Isaac Sim, Isaac Lab y componentes del ecosistema omniverse. Aunque esta fase todavía no culmina en un entorno completamente entrenable, permitió sentar la estructura que deberá alimentar los futuros modelos de RL y permitió identificar con claridad los elementos faltantes y las rutas de acción para completar el diseño.

Un tercer grupo de actividades relevantes consistió en el estudio teórico de los principios fundamentales del aprendizaje por refuerzo. Se revisaron algoritmos, arquitecturas, estrategias de exploración, definiciones de políticas y funciones de valor, así como la relación entre estos conceptos y los subsistemas físicos y sensoriales de un dron. Este estudio teórico se acompañó de la elaboración de reportes técnicos que sistematizan el conocimiento adquirido y sirven como referencia conceptual para la futura implementación de políticas autónomas de navegación, estabilidad, control de actitud y toma de decisiones en tiempo real ante entornos de incendio dinámicos. Si bien el entrenamiento efectivo de políticas aún no se ha realizado, la conceptualización de estados, recompensas, observaciones, acciones y episodios constituye una parte esencial del progreso.

El contraste entre las actividades planteadas inicialmente y las realizadas refleja una adaptación responsable ante la magnitud del proyecto, la necesidad de construir infraestructura técnica desde cero y la reducción del equipo de trabajo. Las metas originales incluían, dentro del mismo periodo, la navegación autónoma avanzada en Isaac Sim, el entrenamiento colaborativo multi-agente y la transferencia de políticas entre distintas configuraciones de drones; sin embargo, tales actividades requieren, por naturaleza, múltiples ciclos de entre-

namiento, validación y refinamiento, así como una base técnica completamente operativa. Por lo tanto, la estancia se centró en construir los cimientos indispensables: comprensión profunda del ecosistema de simulación, validación de herramientas, integración sensorial, familiarización con flujos de trabajo y diseño preliminar del entorno de RL.

En síntesis, aunque las actividades realizadas difieren del alcance final previsto en el anteproyecto, representan un progreso genuino y crítico para garantizar que el proyecto pueda continuar creciendo en etapas posteriores. Se logró avanzar substancialmente en la preparación conceptual, técnica y metodológica, lo cual constituye un indicador claro de cumplimiento ajustado y un punto de partida sólido para desarrollar, en fases futuras, los módulos avanzados de autonomía y colaboración multi-agente originalmente planteados.

VI. PRODUCTOS OBTENIDOS Y SU GRADO DE PARTICIPACIÓN EN LA ELABORACIÓN O DESARROLLO

Los productos obtenidos durante la estancia abarcan tanto resultados experimentales como materiales teóricos, configuraciones técnicas y estructuras preliminares que constituyen la base operativa del proyecto de aprendizaje por refuerzo aplicado a drones para escenarios de incendio. Dado que todas las actividades fueron realizadas por una sola persona, el grado de participación en cada producto fue total, abarcando el diseño, la implementación, el análisis crítico y la documentación asociados.

Uno de los primeros productos generados consistió en la construcción y animación de un modelo preliminar de dron en Blender, el cual permitió comprender de manera práctica los conceptos de esqueleto, jerarquías de articulación, movimiento y representación geométrica. Esta animación se convirtió en la primera evidencia visual del comportamiento dinámico del dron y constituyó una referencia inicial para contrastar el movimiento simulado en motores posteriores. Paralelamente, se desarrolló un proyecto en Unity orientado a simular un control básico tipo WASD del dron, producto que permitió validar aspectos esenciales de mapeo de entradas, desplazamiento en un espacio tridimensional y su respuesta bajo físicas simplificadas. Estos trabajos iniciales funcionaron como prototipos para explorar representaciones alternativas del dron antes de migrar la simulación hacia herramientas más robustas como Isaac Sim.

Un segundo grupo de productos estuvo relacionado con la simulación sensorial. Se implementó un LiDAR funcional en Unity y posteriormente un sensor LiDAR dentro de Isaac Sim, el cual fue conectado exitosamente con ROS. Este producto incluyó la configuración de mensajes, la calibración de parámetros, la validación del barrido tridimensional y la visualización en tópicos ROS, generando evidencia cuantificable sobre la correcta integración entre simulación y middleware robótico. Asimismo, se configuró un sensor IMU en Isaac Sim con salida hacia ROS, obteniendo datos de aceleración, orientación y velocidad angular. Estos productos constituyen avances significativos, pues demuestran la viabilidad de obtener datos sensoriales simulados comparables a un sistema real, requisito indispensable para entrenar agentes mediante RL en entornos tridimensionales. [15]

Un producto particularmente relevante fue el diseño y construcción del proyecto de Isaac Lab orientado al entrenamiento por aprendizaje por refuerzo. Este producto incluye la estructura completa de carpetas, el archivo del entorno (drone_env_cfg.py), la implementación de la configuración del MDP, una primera versión de las recompensas en rewards.py, los archivos YAML con la configuración de PPO para SKRL, los scripts de entrenamiento y evaluación (train.py y play.py), así como la documentación interna del proyecto. Aunque el entorno aún no es plenamente funcional debido a incompatibilidades técnicas en la versión de Isaac Lab empleada, el producto obtenido representa un avance fundamental: establece la arquitectura formal del proyecto y permite que futuros desarrolladores puedan continuar el ciclo de implementación sin comenzar desde cero. La estructura generada sigue el estándar oficial de Isaac Lab, con carpetas dedicadas a tareas, agentes, configuraciones, scripts y extensiones.

Junto con estos productos técnicos, se generó un conjunto extenso de documentos teóricos que abarca los fundamentos de NVIDIA Omniverse, la estructura de Isaac Sim y Isaac Lab, los principios de simulación física, la integración sensorial, la navegación autónoma y los fundamentos del aprendizaje por refuerzo. Estos reportes constituyen evidencia documental que sistematiza los conocimientos adquiridos durante la estancia y funcionan como material de referencia para etapas posteriores del proyecto o para la incorporación de nuevos miembros del equipo. Cada uno de estos documentos fue elaborado íntegramente durante la estancia y vinculado directamente con los desafíos experimentados al trabajar con plataformas avanzadas de simulación robótica.

Asimismo, se produjeron diagnósticos técnicos sobre la viabilidad del proyecto, análisis de compatibilidad entre versiones, registros detallados de errores, trazado de dependencias, mapeo de las funciones obsoletas en Isaac Lab y documentación sobre los pasos necesarios para corregir discrepancias entre módulos. Estos diagnósticos, aunque no constituyen un producto visual, representan un componente crítico del progreso real alcanzado, ya que documentan de manera exhaustiva los obstáculos técnicos encontrados y proporcionan una guía práctica para acelerar la resolución de problemas en futuros ciclos de desarrollo.

Finalmente, los productos obtenidos constituyen un conjunto cohesivo de avances que reflejan tanto el carácter exploratorio de la estancia como la complejidad inherente al proyecto. Aunque el objetivo final —un sistema completo de navegación autónoma mediante RL en entornos de incendio— aún no se ha alcanzado, los resultados obtenidos representan cimientos indispensables para su consecución futura. Todos los productos fueron desarrollados íntegramente por la misma persona, lo que garantiza coherencia metodológica, claridad conceptual y una base sólida para continuar el proyecto dentro de Skyspec.

VII. CONCLUSIÓN

La Experiencia de Vinculación Internacional realizada en Skyspec permitió integrar de manera coherente conocimientos avanzados en simulación robótica, aprendizaje por refuerzo y

diseño de entornos virtuales orientados al desarrollo de drones autónomos para escenarios vinculados con incendios. Aunque el proyecto se encuentra en una fase temprana y originalmente estaba diseñado para un equipo de cinco integrantes, los avances logrados durante este periodo establecen una base técnica y conceptual indispensable para su continuidad. El estudio profundo de NVIDIA Omniverse, Isaac Sim e Isaac Lab, junto con la elaboración de reportes teóricos y experimentos iniciales, permitió comprender los desafíos que implica modelar drones, simular sensores y diseñar arquitecturas de RL capaces de operar en entornos dinámicos y adversos. Estos resultados, aunque preliminares, constituyen el andamiaje sobre el cual podrán desarrollarse políticas más robustas y comportamientos autónomos cada vez más complejos.

En etapas posteriores del proyecto será necesario consolidar el primer entorno completamente funcional en Isaac Lab, de modo que el dron pueda comenzar a entrenarse con tareas básicas como desplazarse hacia coordenadas definidas en el plano horizontal y, posteriormente, tridimensional. Una vez dominada esta primera fase, el siguiente paso consistirá en extender estos comportamientos hacia escenarios más desafiantes, como desplazamientos dentro de almacenes, laberintos o estructuras dañadas, donde el dron deba responder simultáneamente a múltiples fuentes de información sensorial. A largo plazo, el proyecto podrá evolucionar hacia la comparación entre diferentes plataformas aéreas, la transferencia de modelos entre drones con distintas características físicas y la implementación de estrategias colaborativas multi-agente. En conjunto, la estancia permitió adquirir competencias técnicas, analíticas y metodológicas que no solo fortalecen la formación profesional, sino que también ofrecen una plataforma sólida para que el proyecto continúe creciendo y avance hacia soluciones reales de navegación autónoma en escenarios críticos.

VIII. APRENDIZAJES LOGRADOS CON LA EXPERIENCIA DE VINCULACIÓN INTERNACIONAL

La experiencia permitió consolidar un conjunto de aprendizajes técnicos y teóricos avanzados en el ámbito de la simulación robótica, la modelación física y el aprendizaje por refuerzo. En primer lugar, se adquirió un entendimiento profundo de la arquitectura de NVIDIA Omniverse y del rol que desempeñan sus componentes centrales —Universal Scene Description (USD), el sistema de renderizado RTX y los pipelines de simulación física— en la construcción de entornos coherentes, reproducibles y escalables. Esto incluyó el aprendizaje del manejo directo de USD para representar jerarquías de rigid bodies, articulaciones, colisiones, materiales, sensores y transformaciones espaciales dentro de escenas complejas.

En segundo lugar, se desarrollaron competencias avanzadas en Isaac Sim, particularmente en la configuración de escenas físicamente realistas y en la instrumentación de sensores virtuales. Se adquirieron conocimientos técnicos sobre la integración y sincronización de LiDARs, IMUs y cámaras RGB-D dentro del motor de simulación, su calibración cinemática y su conexión con ROS 2 mediante extensiones nativas y canales de comunicación tipo *topic*. Asimismo, se profundizó en el funcionamiento del motor de física PhysX, el manejo de perfiles

de colisión, la configuración de parámetros dinámicos (masa, inercia, damping) y las implicaciones de estas características en la estabilidad del dron dentro del entorno simulado.

En tercer lugar, se obtuvo dominio operativo de Isaac Lab, incluyendo la creación de entornos de entrenamiento para aprendizaje por refuerzo mediante la definición explícita de espacios de observación, espacios de acción, estructuras de recompensa y configuraciones de reseteo. Se comprendió la arquitectura interna del framework, basada en componentes modulares que describen escenas, robots, sensores, orquestadores de simulación y algoritmos de RL. Este aprendizaje incluyó la capacidad de construir *reward functions* analíticas, seleccionar métricas relevantes para navegación aérea, y estructurar pipelines compatibles con algoritmos modernos como Proximal Policy Optimization (PPO).

En el ámbito teórico, la estancia permitió estudiar de forma sistemática los fundamentos del aprendizaje por refuerzo, incluyendo formulación mediante Procesos de Decisión de Markov (MDP), convergencia de políticas, ventaja generalizada (GAE), exploración-estimación, trade-offs entre model-free y model-based RL, así como retos de estabilidad en entornos con alta dimensionalidad sensorial como los drones. Además, se adquirió criterio para analizar configuraciones de recompensas, efectos del *reward shaping*, estabilidad de controladores bajo políticas aprendidas y nociones preliminares de técnicas sim-to-real como *domain randomization*.

Finalmente, se fortalecieron capacidades aplicadas de ingeniería, como depuración de sistemas distribuidos en Omniverse, instrumentación de flujos ROS2 en ambientes simulados, montaje de entornos reproducibles, comprensión de pipelines de optimización GPU y análisis de latencias entre módulos de simulación, sensores y agentes. Este conjunto de aprendizajes constituye una base sólida para la construcción de sistemas autónomos avanzados basados en RL y posiciona el proyecto en un estado técnico adecuado para fases posteriores de entrenamiento y validación.

REFERENCES

- [1] NVIDIA Omniverse - NVIDIA Docs. (s.f.). NVIDIA Docs. <https://docs.nvidia.com/omniverse/index.html>
- [2] NVIDIA Studio Latinoamérica. (2024, March 1). ¿Qué es NVIDIA Omniverse? [Video]. YouTube. <https://www.youtube.com/watch?v=dA-Ehd76QpE>
- [3] NVIDIA Omniverse. (n.d.). GitHub. <https://github.com/NVIDIA-Omniverse>
- [4] What is Isaac Sim? — Isaac Sim documentation. (n.d.). Nvidia.com. Retrieved December 10, 2025, from <https://docs.isaacsim.omniverse.nvidia.com/latest/index.html>
- [5] Welcome to Isaac Lab! — Isaac Lab Documentation. (n.d.). <https://isaac-sim.github.io/IsaacLab/main/index.html>
- [6] Xu, B., Gao, F., Yu, C., Zhang, R., Wu, Y., & Wang, Y. (2024). OmniDrones: An Efficient and Flexible Platform for Reinforcement Learning in Drone Control. *IEEE Robotics and Automation Letters, Robotics and Automation Letters, IEEE, IEEE Robot. Autom. Lett.*, 9(3), 2838–2844. <https://doi.org/10.1109/LRA.2024.3356168>
- [7] Sketchfab. (s.f.). Sketchfab - The best 3D viewer on the web. <https://sketchfab.com/>
- [8] Unity Asset Store. (s.f.). <https://assetstore.unity.com/>
- [9] Superhive (formerly Blender Market). (n.d.) Retrieved August 23, 2025, from <https://superhivemarket.com/>
- [10] Omniverse Unity Connector — NVIDIA NGC. (n.d.). NVIDIA NGC Catalog. Retrieved August 26, 2025, from https://catalog.ngc.nvidia.com/orgs/nvidia/teams/omniverse/resources/omni_unity_connector
- [11] Doya, K., & Morimoto, J. (2001). Acquisition of stand-up behavior by a real robot using hierarchical reinforcement learning. *ELSEVIER*.
- [12] Paola Rojas Domínguez. (2025, August 29). *3D Drone Model - Unity* [Video]. YouTube. https://www.youtube.com/watch?v=EjQ_k_qFU9I
- [13] Paola Rojas Domínguez. (2025b, August 30). *3D Drone Model - Blender* [Video]. YouTube. <https://www.youtube.com/watch?v=ZpNgRCPTsRI>
- [14] Paola Rojas Domínguez. (2025c, October 30). *Lidar Sensor - Unity* [Video]. YouTube. <https://www.youtube.com/watch?v=2Tq9swnpeK0>
- [15] Paola Rojas Domínguez. (2025c, October 30). *Lidar Sensor - Isaac Sim* [Video]. YouTube. <https://www.youtube.com/watch?v=3D1ewOVFFEo>